
SAÉ – ÉCHANTILLONNAGE ET ESTIMATION (OCCITANIE)



TABLE DES MATIERES

SAÉ – Échantillonnage	1
et Estimation	1
(Occitanie)	1
Partie 1 : Estimation du nombre d’habitants d’une région de France	3
1.1 Estimation du nombre d’habitants d’une région de France - Échantillonnage aléatoire simple	3
1.2 Estimation du nombre d’habitants d’une région de France – Échantillonnage aléatoire stratifié	5
Partie 2 : traitement de données d’enquête – Pratique du sport chez les Étudiants	8
ANNEXE : code r	11
PARTIE 1 : échantillons	11
PARTIE 2 Lien avec le sport	13

PARTIE 1 : ESTIMATION DU NOMBRE D'HABITANTS D'UNE RÉGION DE FRANCE

Pour la première partie de cette SAÉ, nous avons tenté d'estimer la population d'une région choisie, à l'aide d'un intervalle de confiance réalisé à partir d'un processus d'échantillonnage. Notre choix s'est porté sur la région Occitanie et nous allons utiliser deux types d'échantillonnage : un aléatoire simple et un autre par strates. Nous allons donc comparer ces deux méthodes afin de déterminer laquelle est la plus efficace.

1.1 ÉSTIMATION DU NOMBRE D'HABITANTS D'UNE REGION DE FRANCE - ÉCHANTILLONNAGE ALÉATOIRE SIMPLE

Notre première étape consiste à importer notre fichier Excel contenant les données sur la population française pour ensuite le filtrer et obtenir un 'Data Frame' (ou un tableau) qui ne contient que les données sur la région Occitanie.

```
library(sampling)
library(readxl)

#import de nos données
table = read.csv2("population_francaise_communes.csv")

##### Partie 1.1#####
#Filtrage des données sur la région d'Occitanie
donnees= table[table$Nom.de.la.région=="Occitanie", c("Code.département", "Commune", "Population.totale")]
head(donnees)
```

Dans notre data frame, nous retrouvons 4454 communes pour un total T (calculé ci-dessous) de 6.97 millions d'habitants dans la région occitane. Pour réaliser notre sondage aléatoire simple et tenter d'estimer la population de notre région, nous avons créé un échantillon aléatoire E de 100 communes occitanes et calculé le nombre moyen d'habitants dans cet échantillon afin de faire un intervalle de confiance (IDC) à 95% de notre nombre moyen, pour enfin estimer la taille de la population totale (T estimée) et faire un IDC pour cette population totale estimée.

```
# création d'un échantillon de 100 communes
n= 100
E= sample(U,n)

# création d'une table
donnees1= donnees[donnees$Commune%in% E,]

# calcul du nombre moyen d'habitant
xbar= mean(donnees1$Population.totale)

idcmoy = t.test(donnees1$Population.totale)$conf.int

#estimation du nombre d'habitant total à partir de l'échantillon
T_est = N* xbar

#une intervalle de confiance pour T
idcT = idcmoy*N

#marge d'erreur
marge= (idcT[2]-idcT[1])/2
```

Notre méthode est fonctionnelle cependant très redondante donc nous allons automatiser et itérer, à l'aide d'une boucle, l'opération dix fois afin d'obtenir un tableau Excel et un graphique représentant nos estimations.

```
#initialisation d'une dataframe resultats pour stocker les dix résultats
resultats= data.frame(pop_totale= numeric(), pop_estim= numeric(),Borne_inf=numeric(), Borne_sup=numeric(), Marge= numeric())


# création d'une boucle pour générer nos résultats
for (i in 1:10){
  E= sample(U,n)
  donnees1= donnees[donnees$Commune%in% E,]
  xbar= mean(donnees1$Population.totale)
  idcmoy = t.test(donnees1$Population.totale)$conf.int
  T_est = N* xbar
  idcT = idcmoy*N
  marge= (idcT[2]-idcT[1])/2

  new_row = data.frame(pop_totale =T, pop_estim= T_est,Borne_inf=idcT[1], Borne_sup=idcT[2], Marge=marge)
  resultats=rbind(resultats, new_row)
}

#~création d'un fichier csv pour pouvoir apercevoir notre tableau et construire le graphique
write.csv2(resultats, "resultats_estimations.csv", row.names= FALSE)
```

	Population totale	Population estimée	IDC borne inférieure	IDC borne supérieure	Marge
1	6097513	6006893,229	3844663,68	8169122,779	2162229,55
2	6097513	6689302,602	1170148,371	12208456,83	5519154,23
3	6097513	3671451,565	2305829,624	5037073,507	1365621,94
4	6097513	3536591,19	2463188,325	4609994,054	1073402,86
5	6097513	5573952,056	297875,664	10850028,45	5276076,39
6	6097513	6177131,127	2395719,601	9958542,654	3781411,53
7	6097513	3575585,246	2539285,32	4611885,171	1036299,93
8	6097513	3948471	2939333,929	4957608,071	1009137,07
9	6097513	8106153,943	2860558,211	13351749,68	5245595,73
10	6097513	3537509,964	2179374,284	4895645,645	1358135,68

Nous obtenons donc le tableau suivant contenant notre population totale, la population estimée, notre IDC avec sa borne inférieure et sa borne supérieure ainsi que sa marge d'erreur. Ce tableau nous permet donc de construire le graphique ci-dessous.



Notre graphique montre une grande disparité entre nos estimations, prouvant le manque de précision du sondage aléatoire simple. En effet, même si la première, deuxième et sixième estimation sont proches de la réalité, les autres en sont assez loin. De plus, la moyenne des estimations est de 5,08 millions d'habitants, ce qui est un million de moins que la population réelle occitane. Cette différence peut s'expliquer par la très grande superficie de la région et surtout par son nombre considérable de petites

communes, notamment en Ariège (09) ou en Lozère (48), ce qui a potentiellement pu biaiser notre estimation.

On peut donc émettre la théorie que l'on obtienne des résultats plus précis et proches de la réalité en utilisant une autre méthode de sondage, par exemple la méthode des sondages stratifiés.

1.2 ÉSTIMATION DU NOMBRE D'HABITANTS D'UNE RÉGION DE FRANCE – ÉCHANTILLONAGE ALÉATOIRE STRATIFIÉ

Notre seconde étape consiste à reprendre notre travail de la partie 1.1, en adoptant un échantillonnage stratifié. Nous avons commencé par choisir comme strates les quartiles de la population totale de la région, que nous avons trouvé grâce à la fonction suivante :

summary(donnees\$Population.totale)

Fort de ce constat, nous avons créé 10 strates basées sur des seuils de population correspondant aux ruptures naturelles de la distribution (très petites communes < 100 hab., jusqu'aux grandes agglomérations > 50 000 hab.). Ce choix est préféré à des strates définies par les seuls quantiles car il reflète mieux la réalité des disparités de population entre communes.

```
# Nous avons créée 7 groupes de populations allant de moins de 2500 à plus de 200 000

#1 - Création des 10 strates
donnees$strate = cut(donnees$Population.totale,
breaks = c(0, 100, 200, 500, 1000, 2000, 5000, 10000, 25000, 50000, 510000), labels = c(1,2,3,4,5,6,7,8,9,10))

#2
# créer une nouvelle table pour contenir la table "donnees" et la colonne strate
datastrat = donnees[,c("Commune", "Population.totale", "strate")]
head(datastrat)
table(datastrat$strate)

#3
# sondage stratifiés (donnees triées par strate)
data = datastrat[order(datastrat$strate), ]

# effectif des strates
Nh = table(data$strate)

N = sum(Nh)

# Poids des strates
gh = Nh/N
```

La table datastrat contient les mêmes communes que la table données, auxquelles s'ajoute la colonne « strate ». La commande table(datastrat\$strate) nous permet de vérifier que chaque strate est non vide, ce qui est indispensable pour éviter les erreurs dans le tirage.

```

#initialisation d'une dataframe resultats pour stocker les données stratifiées
resultats_stratifies= data.frame(pop_totale= numeric(), pop_estim= numeric(),Borne_inf=numeric(), Borne_sup=numeric(), Marge= numeric())

for (i in 1:10) {

# Tirage d'un échantillon stratifié de taille 100
n = 100

nh = round(c(n*Nh[1]/N, n*Nh[2]/N, n*Nh[3]/N, n*Nh[4]/N, n*Nh[5]/N, n*Nh[6]/N, n*Nh[7]/N, n*Nh[8]/N, n*Nh[9]/N, n*Nh[10]/N))

# Minimum 1 par strate et maximum = effectif de la strate
nh = pmax(nh, 1)
nh = pmin(nh, Nh)

# taux de sondage dans les strates
fh = nh/Nh

# sondage stratifié sans remise
library(sampling)

st = strata(data, stratanames = c("strate"),size = nh,method = "srswr")

data1 = getdata(data, st)

#4 - Sous-échantillons par strate
ech1 = data1[data1$strate == 1, ]
ech2 = data1[data1$strate == 2, ]
ech3 = data1[data1$strate == 3, ]
ech4 = data1[data1$strate == 4, ]
ech5 = data1[data1$strate == 5, ]
ech6 = data1[data1$strate == 6, ]
ech7 = data1[data1$strate == 7, ]
ech8 = data1[data1$strate == 8, ]
ech9 = data1[data1$strate == 9, ]
ech10 = data1[data1$strate == 10,]

# moyenne des 4 sous-échantillons
m1= mean(ech1$Population.totale)
m2= mean(ech2$Population.totale)
m3= mean(ech3$Population.totale)
m4 = mean(ech4$Population.totale)
m5 = mean(ech5$Population.totale)
m6 = mean(ech6$Population.totale)
m7 = mean(ech7$Population.totale)
m8 = mean(ech8$Population.totale)
m9 = mean(ech9$Population.totale)
m10 = mean(ech10$Population.totale)

# variances des 4 sous-échantillons
var1= var(ech1$Population.totale)
var2= var(ech2$Population.totale)
var3= var(ech3$Population.totale)
var4= var(ech4$Population.totale)
var5 = var(ech5$Population.totale)
var6 = var(ech6$Population.totale)
var7 = var(ech7$Population.totale)
var8 = var(ech8$Population.totale)
var9 = var(ech9$Population.totale)
var10 = var(ech10$Population.totale)

#5 - Moyenne stratifiée
Xbarst <- sum(gh * c(m1,m2,m3,m4,m5,m6,m7,m8,m9,m10))

# Variance des strates (NA + 0 si nh=1)
var_h <- c(var1,var2,var3,var4,var5,var6,var7,var8,var9,var10)
var_h[is.na(var_h)] <- 0

# Estimation de la variance de Xbarst
varXbarst <- sum(gh^2 * (1 - fh) * var_h / nh)

# IDC pour µ à 95%
alpha <- 0.05
binf <- Xbarst - qnorm(1 - alpha/2) * sqrt(varXbarst)
bsup <- Xbarst + qnorm(1 - alpha/2) * sqrt(varXbarst)
idcmoy <- c(binf, bsup)

#6 - Estimation du total T
Tstr <- N * Xbarst
idcT <- idcmoy * N
marge <- (idcT[2] - idcT[1]) / 2

new_row2 <- data.frame(pop_totale = T, pop_estim = Tstr,
                      Borne_inf = idcT[1], Borne_sup = idcT[2], Marge = marge)
resultats_stratifies <- rbind(resultats_stratifies, new_row2) # + plus de écrasement

```

Cette boucle effectue une estimation répétée par sondage stratifié pour évaluer la population totale de la région Occitanie. Elle crée d'abord un data frame vide pour stocker les résultats et répète ensuite dix fois l'expérience de sondage : à chaque itération, un échantillon est tiré de manière aléatoire avec remise dans chaque strate définie par la variable "strate". Pour chaque strate, la moyenne et la variance de la population totale sont calculées. Ces estimations sont ensuite combinées pour obtenir une moyenne stratifiée (Xbarst) et sa variance (varXbarst), à partir desquelles un intervalle de confiance à 95 % est construit pour l'estimation totale (Tstr). Les bornes de cet intervalle et la marge d'erreur sont calculées et enregistrées dans le tableau de résultats. Une fois que la boucle est finie, les résultats sont compilés dans un fichier nommé « résultats_stratifiés » grâce à la fonction suivante :


```
write.csv2(resultats_stratifies, "resultats_stratifies.csv", row.names = FALSE)
```

Ce document créé automatiquement est bien plus simple et plus rapide à exploiter et nous a permis de faire de nombreux tests. En effet, nous avons réalisé un premier test avec 4 strates équivalentes aux quartiles, mais les résultats n'étaient pas pertinents voir pire que le sondage aléatoire simple. Ces tests nous ont montré que la seule différence notable au niveau de nos résultats n'apparaissait que quand nous effectuons des sondages aléatoires stratifiés à 10 strates.

	population totale	population estimée	IDC Inferieur	IDC Superieur	Marge
1	6097513	5549225,752	5248242,679	5850208,825	300983,073
2	6097513	5263107,174	4990781,107	5535433,241	272326,067
3	6097513	6656945,207	6331871,224	6982019,189	325073,983
4	6097513	5701664,723	5463623,4	5939706,047	238041,324
5	6097513	5925871,188	5669210,383	6182531,993	256660,805
6	6097513	5143098,721	4956102,603	5330094,839	186996,118
7	6097513	5290784,293	4983062,724	5598505,862	307721,569
8	6097513	7259943,465	7040562,926	7479324,004	219380,539
9	6097513	5145364,502	4834885,413	5455843,59	310479,088
10	6097513	5504533,636	5185236,027	5823831,246	319297,61

Estimation de la population occiatne par un sondage aléatoire en 10 strates



En comparant les deux graphiques obtenus, on observe que les estimations les plus proches de la réalité (population estimée) ont été obtenues en faisant un sondage à 10 strates. Dans le meilleur graphique, la plus grande différence entre la réalité et la population totale estimée est aux alentours de 320 mille habitants, ce qui est beaucoup moins que les marges du sondage aléatoire simple. De plus, la moyenne des estimations est de 5,7 millions d'habitants, ce qui est légèrement en dessous de la réalité mais qui reste meilleur que la moyenne de 5,08 millions d'habitants obtenue par le sondage aléatoire simple.

Dans l'ensemble, il reste clair que le sondage aléatoire stratifié nous permet d'obtenir de meilleurs résultats que le sondage aléatoire simple, même si notre constat est que l'on manque de précision. L'idée de changer le nombre de strates était bonne et nous a permis d'obtenir des estimations plus précises, mais trouver d'autres strates/ d'autres manières de les faire autrement qu'en se reposant sur les quantiles aurait aussi pu nous permettre d'obtenir des résultats intéressants.

PARTIE 2 : TRAITEMENT DE DONNÉES D'ENQUÊTE – PRATIQUE DU SPORT CHEZ LES ÉTUDIANTS

Dans cette deuxième partie de la SAE, nous étudions les données de l'enquête réalisée auprès des étudiants concernant la pratique sportive. L'objectif est de rechercher des relations significatives entre la variable « Sport » et plusieurs autres variables qualitatives du questionnaire.

Par conséquent, nous allons utiliser des tableaux croisés ainsi que des tests du khi-deux d'indépendance afin de déterminer si certaines variables influencent significativement la pratique sportive. Lorsque nous considérons les résultats significatifs, nous mesurerons également l'intensité de la liaison grâce au coefficient V de Cramer.

Nous avons dans un premier temps importer le fichier afin de pouvoir davantage explorer les données de l'enquête et ainsi de déterminer quelles variables seraient considérées pertinentes selon nous

1. Import des données

```
table <- read.csv2("EnqueteSportEtudiant2024.csv")
```

Le fichier utilisé contenait 76 variables et 375 réponses d'une enquête réalisée auprès d'étudiants ayant répondu au questionnaire. Les variables correspondent aux différentes questions posées dans l'enquête soit les pratiques sportive, sexe, logement, alimentation, tabac, santé, niveau d'étude, etc.

La majorité des variables sont qualitatives, car elles décrivent des catégories ou des modalités de réponse. Certaines variables peuvent également être quantitatives ou ordinales selon les informations recueillies. Après l'analyse de notre table, nous l'avons réduit à 11 variables car certaines n'étaient pas assez complètes (manque de réponses, N/A ou réponses trop spécifiques)

```
#2 On supprime les colonnes multi-réponses (typessportavant_X, sportnonuaps_X,
# cadresport_X, etc.) qui ne sont pas des variables qualitatives classiques,
# ainsi que les champs "Autre" texte libre et les colonnes sans intérêt pour
# notre analyse.

tablesport <- table %>%
  select(
    sport,
    sexe,
    niveau,
    deptformation,
    alternant,
    bourse,
    travail,
    logement,
    fumer,
    alimentation,
    sante
  ) %>%
  # On supprime les lignes avec des modalités "Autre" dans logement,
  filter(logement != "Autre") %>%
  # On supprime les lignes où sport est vide (non-réponse)
  filter(sport != "" & !is.na(sport))
```

Après l'étude des variables restantes, nous avons choisi celles qui semblaient les plus intéressantes et plausibles d'avoir un impact sur la pratique du sport chez un étudiant. Les variables choisies étaient les suivantes : le sexe, le fait d'être alternant ou non, le département de formation, le niveau d'études, le type

de logement, le fait d'être fumeur ou non, le fait d'avoir une bonne qualité d'alimentation ou non et le fait d'être en bonne santé ou non.

```
#Création des tableaux croisés dynamiques entre la variable sport et d'autres
TCD_Sexe = table(tablesport$sport, tablesport$sexe)
TCD_Alternant = table(tablesport$sport, tablesport$alternant)
TCD_Dept = table(tablesport$sport, tablesport$deptformation)
TCD_niveau = table(tablesport$sport, tablesport$niveau)
TCD_logement = table(tablesport$sport, tablesport$logement)
TCD_fumer = table(tablesport$sport, tablesport$fumer)
TCD_alimentation = table(tablesport$sport, tablesport$alimentation)
TCD_sante = table(tablesport$sport, tablesport$sante)
```

Afin de comparer chaque variable, nous avons créé des tableaux croisés dynamiques sur lesquels nous avons commencé par faire les tests du khi-deux d'indépendance ainsi que le test du V de Cramer avec le code suivant :

```
# Test du khi2 pour chaque variable/TCD
khideux_Sexe= chisq.test (TCD_Sexe)
khideux_Sexe
```

Nous avons répété ce test 8 fois pour chacune des variables qualitatives que nous avons décidé de croiser avec la variable sport, et de même pour le V de Cramer (exemple avec le croisement sport/sexe) :


```
# V de Cramer pour chaque variable
n <- dim(tablesport) [1]
p <- nrow(TCD_Sexe)
q <- ncol(TCD_Sexe)
m <- min(p-1, q-1)
V_Sexe =sqrt(khideux_Sexe$statistic/(n*m))
V_Sexe
```

Pour comparer nos résultats sur chaque croisement, nous avons pris les données obtenues et les avons mises dans un tableau Excel, dans lequel nous trouvons les données suivantes :

Variable	P_valeur	Significatif	V_Cramer
sexe	3,00E-04	OUI ***	0,191
niveau	0,0228	OUI ***	0,176
deptformation	6,00E-04	OUI ***	0,219
alternant	0,0415	OUI ***	0,132
logement	0,2156	non	0,065
fumer	0,5733	non	0,027
alimentation	3,00E-04	OUI ***	0,188
sante	0,6011	non	0,027

Et nous avons réalisé un graphique pour que ce soit plus lisible grâce à ggplot sur R

Intensité des liaisons avec la pratique sportive (V de Cramer)



En observant ces résultats, on peut voir que parmi les 8 p-valeurs obtenues, quatre d'entre elles sont bien plus petites que les autres et nous indiquent qu'il y a une relation significative entre le sport et ces variables : le sexe, le niveau d'études, le département de formation, le statut d'alternant ainsi que l'alimentation. Les quatre autres p-valeurs (logement, fumer, santé) sont bien trop grandes et constituent une preuve plus ou moins modérée envers l'hypothèse d'indépendance ; ces variables n'expliquent pas la pratique du sport.

En allant plus loin et en comparant le V de Cramer, les résultats obtenus sur ces quatre variables significatives sont là encore meilleurs que ceux des autres variables. Cependant, aucune liaison ne peut être qualifiée de forte ou même de modérée : toutes les valeurs sont comprises entre 0,13 et 0,22, ce qui indique uniquement des liaisons faibles. La liaison la plus forte est celle entre le sport et le département de formation avec un V de Cramer à 0,219, suivi de près par le sexe (0,191) et l'alimentation (0,188). Le niveau d'études (0,176) et le statut d'alternant (0,132) présentent également des liaisons faibles mais significatives. Les variables non significatives affichent quant à elles des V de Cramer très proches de 0, ce qui confirme l'absence totale de lien avec la pratique sportive.

À l'issue de cette analyse exploratoire des données issues de l'enquête sur le sport, nous avons pu identifier certaines relations significatives entre la pratique sportive et des variables qualitatives précises. Grâce aux tests du khi-deux et au calcul du V de Cramer réalisés sur les croisements entre la variable « sport » et huit autres variables qualitatives, il ressort que cinq d'entre elles — le sexe, le niveau d'études, le département de formation, le statut d'alternant et la qualité de l'alimentation — présentent une relation statistiquement significative avec la pratique sportive.

Cependant, l'intensité de ces relations reste modeste. Aucune liaison ne dépasse le seuil de 0,22, ce qui signifie que toutes les relations identifiées sont faibles. La liaison la plus forte est celle entre le sport et le département de formation (V de Cramer $\approx 0,219$), suivie du sexe ($\approx 0,191$) et de l'alimentation ($\approx 0,188$). Le niveau d'études et le statut d'alternant présentent également des liaisons significatives mais encore plus ténues. Les autres variables, telles que le type de logement, le tabagisme ou la perception de la santé, ne montrent pas de lien notable avec la pratique sportive dans ce contexte.

Ces résultats mettent en lumière l'influence de certaines dimensions sur les comportements sportifs des étudiants, notamment leur filière de formation, leur genre et leurs habitudes alimentaires. Ils suggèrent également que d'autres facteurs, potentiellement non mesurés dans cette enquête, pourraient jouer un rôle déterminant. Une analyse plus poussée avec des données complémentaires, par exemple le temps disponible ou les revenus, permettrait d'enrichir cette première exploration.

ANNEXE : CODE R

PARTIE 1 : ECHANTILLONS

```

library(sampling)
library(readxl)

#-----Partie 1-----#

#1
#Importer les données sur les différentes région
table = read.csv2("population_francaise_commune.csv")

#Création d'une fata frame
donnees= table[table$Nom.de.la.région=="Occitanie", c("Code.département", "Commune", "Population.totale")]
head(donnees)

#2
# Création de la variable U avec les communes
U = donnees$Commune
head(U)

#2
# Variable U = l'ensemble des communes belges , les indiv sont les communes
U = donnees$Commune
head(U)
# Nombre de communes dans U
N = length(U)
head(N)

#3
# Supprimer les espaces
donnees$Population.totale <- gsub(" ", "", donnees$Population.totale)
# Convertir en numérique
donnees$Population.totale <- as.numeric(donnees$Population.totale)
# nombre T exact d'habitants en Occitanie
T = sum(donnees$Population.totale)

#4
# création d'un échantillon de 100 communes
n= 100
E= sample(U,n)
head(E)

#5
# création d'une table
donnees1= donnees[donnees$Commune%in% E,]
head(donnees1)

#6
# calcul du nombre moyen d'habitant
xbar= mean(donnees1$Population.totale)

idcmoy = t.test(donnees1$Population.totale)$conf.int

#7- estimation du nombre d'habitant total à partir de l'échantillon

T_est = N* xbar
T_est

# une intervalle de confiance pour T
idcT = idcmoy*N
idcT
# marge d'erreur
marge= (idcT[2]-idcT[1])/2
marge

#8
#initialisation d'une dataframe resultats pour stockés les dix résultats
resultats= data.frame(pop_totale= numeric(), pop_estim= numeric(),Borne_inf=numeric(), Borne_sup=numeric(), Marge= numeric())

# création d'une boucle
for (i in 1:10){
  E= sample(U,n)
  donnees1= donnees[donnees$Commune%in% E,]
  xbar= mean(donnees1$Population.totale)
  idcmoy = t.test(donnees1$Population.totale)$conf.int
  T_est = N* xbar
  idcT = idcmoy*N
  marge= (idcT[2]-idcT[1])/2

  new_row = data.frame(pop_totale =T, pop_estim= T_est,Borne_inf=idcT[1], Borne_sup=idcT[2], Marge=marge)
  resultats=rbind(resultats, new_row)
}

#~création d'un fichier csv
write.csv2(resultats, "resultats_estimations.csv", row.names= FALSE)

min(donnees$Population.totale)

```

```

#-----Partie 1.2-----#

# Définir les quantiles de la variables Population totale
summary(donnees$Population.totale)

# Nous avons créée 7 groupes de populations allant de moins de 2500 à plus de 200 000

#1 - Création des 10 strates
donnees$strate = cut(donnees$Population.totale,
breaks = c(0, 100, 200, 500, 1000, 2000, 5000, 10000, 25000, 50000, 510000),labels = c(1,2,3,4,5,6,7,8,9,10))

#2
# créer une nouvelle table pour contenir la table "donnees" et la colonne strate
datastrat = donnees[,c( "Commune", "Population.totale", "strate")]
head(datastrat)
table(datastrat$strate)

#3
# sondage stratifiés (donnees triées par strate)
data = datastrat[order(datastrat$strate), ]

# effectif des strates
Nh = table(data$strate)

N = sum(Nh)

# Poids des strates
gh = Nh/N

#initialisation d'une dataframe resultats pour stocker les données stratifié
resultats_stratifies= data.frame(pop_totale= numeric(), pop_estim= numeric(),Borne_inf=numeric(), Borne_sup=numeric(), Marge= nume

for (i in 1:10) {

# Tirage d'un échantillon stratifié de taille 100
n = 100

nh = round(c(n*Nh[1]/N, n*Nh[2]/N, n*Nh[3]/N, n*Nh[4]/N, n*Nh[5]/N, n*Nh[6]/N, n*Nh[7]/N, n*Nh[8]/N, n*Nh[9]/N, n*Nh[10]/N))

# Minimum 1 par strate et maximum = effectif de la strate
nh = pmax(nh, 1)
nh = pmin(nh, Nh)

# taux de sondage dans les strates
fh = nh/Nh

# sondage stratifié sans remise
library(sampling)

st = strata(data , stratanames = c("strate"),size = nh,method = "srswr")

data1 = getdata(data, st)

#4 - Sous-échantillons par strate
ech1 = data1[data1$strate == 1, ]
ech2 = data1[data1$strate == 2, ]
ech3 = data1[data1$strate == 3, ]
ech4 = data1[data1$strate == 4, ]
ech5 = data1[data1$strate == 5, ]
ech6 = data1[data1$strate == 6, ]
ech7 = data1[data1$strate == 7, ]
ech8 = data1[data1$strate == 8, ]
ech9 = data1[data1$strate == 9, ]
ech10 = data1[data1$strate == 10,]

# moyenne des 4 sous-échantillons
m1= mean(ech1$Population.totale)
m2= mean(ech2$Population.totale)
m3= mean(ech3$Population.totale)
m4 = mean(ech4$Population.totale)
m5 = mean(ech5$Population.totale)
m6 = mean(ech6$Population.totale)
m7 = mean(ech7$Population.totale)
m8 = mean(ech8$Population.totale)
m9 = mean(ech9$Population.totale)
m10 = mean(ech10$Population.totale)

# variances des 4 sous-échantillons
var1= var(ech1$Population.totale)
var2= var(ech2$Population.totale)
var3= var(ech3$Population.totale)
var4= var(ech4$Population.totale)
var5 = var(ech5$Population.totale)
var6 = var(ech6$Population.totale)
var7 = var(ech7$Population.totale)
var8 = var(ech8$Population.totale)
var9 = var(ech9$Population.totale)
var10 = var(ech10$Population.totale)

#5 - Moyenne stratifiée
Xbarst <- sum(gh * c(m1,m2,m3,m4,m5,m6,m7,m8,m9,m10))

```

```

# Variance des strates (NA → 0 si nh=1)
var_h <- c(var1,var2,var3,var4,var5,var6,var7,var8,var9,var10)
var_h[is.na(var_h)] <- 0

# Estimation de la variance de Xbarst
varXbarst <- sum(gh^2 * (1 - fh) * var_h / nh)

# IDC pour  $\mu$  à 95%
alpha <- 0.05
binf <- Xbarst - qnorm(1 - alpha/2) * sqrt(varXbarst)
bsup <- Xbarst + qnorm(1 - alpha/2) * sqrt(varXbarst)
idcmoy <- c(binf, bsup)

#6 - Estimation du total T
Tstr <- N * Xbarst
idcT <- idcmoy * N
marge <- (idcT[2] - idcT[1]) / 2

new_row2 <- data.frame(pop_totale = T, pop_estim = Tstr,
                      Borne_inf = idcT[1], Borne_sup = idcT[2], Marge = marge)
resultats_stratifies <- rbind(resultats_stratifies, new_row2) # ← plus de écrasement
}

print(resultats_stratifies)
write.csv2(resultats_stratifies, "resultats_stratifies.csv", row.names = FALSE)

```

PARTIE 2 LIEN AVEC LE SPORT

```

library(sampling)
library(readxl)
library(dplyr)

# 1. Import des données

table <- read.csv2("EnqueteSportEtudiant2024.csv")

#2 On supprime les colonnes multi-réponses (typessportavant_X, sportsnonuaps_X,
# cadresport_X, etc.) qui ne sont pas des variables qualitatives classiques,
# ainsi que les champs "Autre" texte libre et les colonnes sans intérêt pour
# notre analyse.

tablesport <- table %>%
  select(
    sport,
    sexe,
    niveau,
    deptformation,
    alternant,
    bourse,
    travail,
    logement,
    fumer,
    alimentation,
    sante
  ) %>%
  # On supprime les lignes avec des modalités "Autre" dans logement,
  filter(logement != "Autre") %>%
  # On supprime les lignes où sport est vide (non-réponse)
  filter(sport != "" & !is.na(sport))

#Création des tableaux croisés dynamiques entre la variable sport et d'autres
TCD_Sexe = table(tablesport$sport, tablesport$sexe)
TCD_Alternant = table(tablesport$sport, tablesport$alternant)
TCD_Dept = table(tablesport$sport, tablesport$deptformation)
TCD_niveau = table(tablesport$sport, tablesport$niveau)
TCD_logement = table(tablesport$sport, tablesport$logement)
TCD_fumer = table(tablesport$sport, tablesport$fumer)
TCD_alimentation = table(tablesport$sport, tablesport$alimentation)
TCD_sante = table(tablesport$sport, tablesport$sante)

# Test du khi2 pour chaque variable/TCD
khideux_Sexe= chisq.test (TCD_Sexe)
khideux_Sexe

```



```

n <- dim(tablesport) [1]
p <- nrow(TCD_alimentation)
q <- ncol (TCD_alimentation)
m <- min(p-1, q-1)
V_alimentation =sqrt(khideux_alimentation$statistic/(n*m))
V_alimentation

```

```

n <- dim(tablesport) [1]
p <- nrow(TCD_Dept)
q <- ncol(TCD_Dept)
m <- min(p-1, q-1)
V_Dept =sqrt(khideux_Dept$statistic/(n*m))
V_Dept

```

```

n <- dim(tablesport) [1]
p <- nrow(TCD_Alternant)
q <- ncol (TCD_Alternant)
m <- min(p-1, q-1)
V_Alternant =sqrt(khideux_Alternant$statistic/(n*m))
V_Alternant

```

```

n <- dim(tablesport) [1]
p <- nrow(TCD_niveau)
q <- ncol (TCD_niveau)
m <- min(p-1, q-1)
V_niveau =sqrt(khideux_niveau$statistic/(n*m))
V_niveau

```

```

n <- dim(tablesport) [1]
p <- nrow(TCD_logement)
q <- ncol (TCD_logement)
V_logement =sqrt(khideux_logement$statistic/(n*m))
V_logement

```

```

n <- dim(tablesport) [1]
p <- nrow(TCD_sante)
q <- ncol (TCD_sante)
m <- min(p-1, q-1)
V_sante =sqrt(khideux_sante$statistic/(n*m))
V_sante

```

```

# tableau recapitulatif

resultats <- data.frame(
  Variable = c("sexe", "niveau", "deptformation", "alternant",
               "logement", "fumer", "alimentation", "sante"),
  P_valeur = round(c(khideux_Sexe$p.value, khideux_niveau$p.value,
                    khideux_Dept$p.value, khideux_Alternant$p.value,
                    khideux_logement$p.value, khideux_fumer$p.value,
                    khideux_alimentation$p.value, khideux_sante$p.value), 4),
  Significatif = ifelse(c(khideux_Sexe$p.value, khideux_niveau$p.value,
                        khideux_Dept$p.value, khideux_Alternant$p.value,
                        khideux_logement$p.value, khideux_fumer$p.value,
                        khideux_alimentation$p.value, khideux_sante$p.value) < 0.05,
                        "OUI ***", "non"),
  V_Cramer = round(c(as.numeric(V_Sexe), as.numeric(V_niveau),
                    as.numeric(V_Dept), as.numeric(V_Alternant),
                    V_logement, as.numeric(V_sante),
                    as.numeric(V_alimentation), as.numeric(V_sante)), 3),
  stringsAsFactors = FALSE
)

resultats

# — 3. Export en CSV

write.csv2(resultats, "resultats_vcramer.csv", row.names = FALSE)
cat("Fichier exporté : resultats_vcramer.csv\n")

#Graphique avec ggplot
# On trie les variables par V de Cramer croissant pour une meilleure lisibilité
res_tri <- resultats[order(resultats$V_Cramer), ]

barplot(
  height = res_tri$V_Cramer,
  names.arg = res_tri$Variable,
  col = ifelse(res_tri$Significatif == "OUI ***", "red", "orange"),
  horiz = TRUE,
  las = 1,
  main = "Intensité des liaisons avec la pratique sportive (V de Cramer)",
  xlab = "V de Cramer",
  cex.names = 0.85,
  xlim = c(0, 0.25)
)
abline(v = 0.10, lty = 2, col = "black", lwd = 1.5)
text(0.105, 0.6, "V = 0,10 (seuil faible)", cex = 0.75, col = "grey40", adj = 0)
legend("bottomright",
  legend = c("Significatif (p < 0,05)", "Non significatif"),
  fill = c("red", "orange"), cex = 0.85, bty = "n")

```